Aprendizaje automático mediante modelos híbridos cuántico-clásicos con circuitos cuánticos variacionales para la clasificación de imágenes

Sebastián González Juárez[1], Jimena Olveres Montiel[2] , Boris Escalante Ramírez[2]

[1] Facultad de Ciencias, Universidad Nacional Autónoma de México (UNAM), Ciudad de México, México
[2] Facultad de Ingeniería, Universidad Nacional Autónoma de México (UNAM), Ciudad de México, México

Resumen

Se presenta el diseño e implementación de un marco computacional basado en simulaciones de circuitos cuánticos para integrar extractores locales fundamentados en circuitos cuánticos variacionales, bajo el esquema de quanvolution, dentro de arquitecturas híbridas cuántico–clásicas para la clasificación de imágenes. El método aplica circuitos parametrizados sobre parches espaciales, de forma análoga a una convolución clásica, y utiliza mediciones de observables para generar mapas de características posteriormente procesados por redes neuronales convolucionales. La contribución principal es el desarrollo, por primera vez en el laboratorio, de una arquitectura híbrida funcional y reproducible que integra módulos cuánticos y clásicos en un flujo de entrenamiento unificado. Implementado con PennyLane y PyTorch, el sistema permitió evaluar su desempeño frente a modelos puramente clásicos en un entorno controlado de simulación, estableciendo una base para futuras investigaciones en aprendizaje automático cuántico.

Introducción

Los modelos híbridos cuántico–clásicos incorporan circuitos cuánticos variacionales para ampliar la representación de características en la clasificación de imágenes. En este trabajo se implementa un marco reproducible que integra extractores locales tipo quanvolution y permite evaluar su desempeño en simulación.

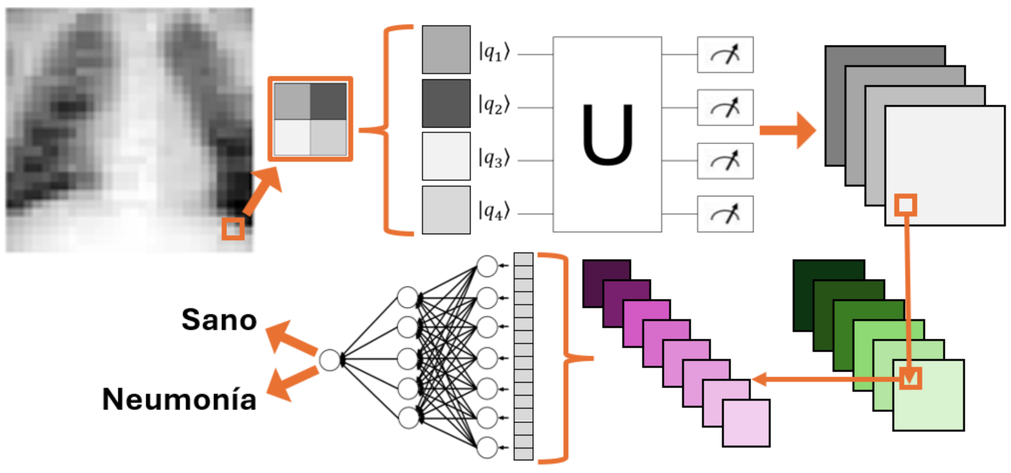

Fig. 1. Diagrama de bloques del modelo HQCNN propuesto.

Metodología

La imagen del conjunto PneumoniaMNIST se divide en parches espaciales de tamaño 4x4 píxeles, cuyos valores son codificados en estados cuánticos mediante rotaciones $R_Y(\pi x)$, dentro de un circuito cuántico de 4 qubits.

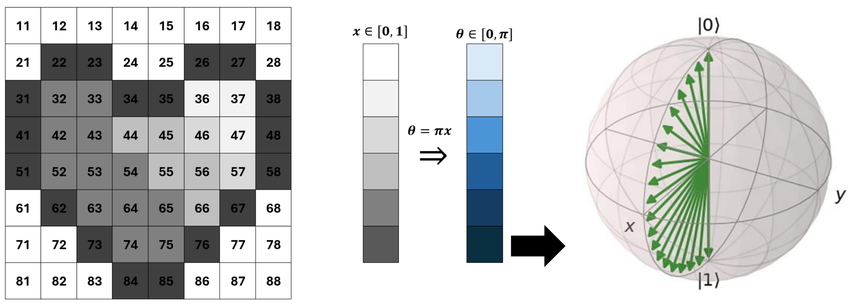

Fig. 2. Codificación de píxeles mediante rotaciones $R_Y(\pi x)$ en la esfera de Bloch.

Posteriormente, los estados son procesados por un circuito variacional compuesto por capas alternadas de rotaciones parametrizadas $R_Y(\theta)$, $R_Z(\phi)$ y compuertas de entrelazamiento tipo CNOT dispuestas en un patrón tipo anillo, cuya profundidad es controlada mediante la repetición de bloques.

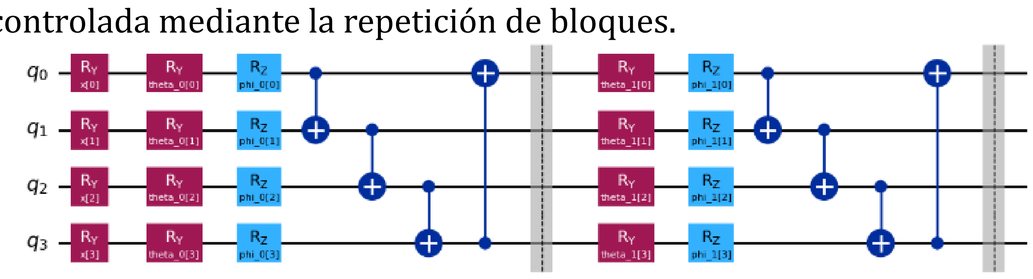

Fig. 3. Estructura del circuito cuántico variacional utilizado en la arquitectura híbrida.

Expresión matemática completa del circuito cuántico para L capas:

$$|\psi_{\text{out}}(x;\Theta,\Phi)\rangle = \left[\prod_{\ell=1}^{L}\left(U_{\text{ring}}\bigotimes_{w=0}^{3} R_Z(\phi_{\ell,w})\,R_Y(\theta_{\ell,w})\right)\right]\left(\bigotimes_{w=0}^{3} R_Y(\pi x_w)\right)|0000\rangle$$

$$U_{\text{ring}} = \text{CNOT}_{3\to0}\,\text{CNOT}_{2\to3}\,\text{CNOT}_{1\to2}\,\text{CNOT}_{0\to1}$$

La salida cuántica se obtiene midiendo los valores esperados $\langle Z_\omega\rangle$ de cada qubit, lo que genera 4 características por parche; al barrer todos los parches se forman 4 mapas de características (4 canales).

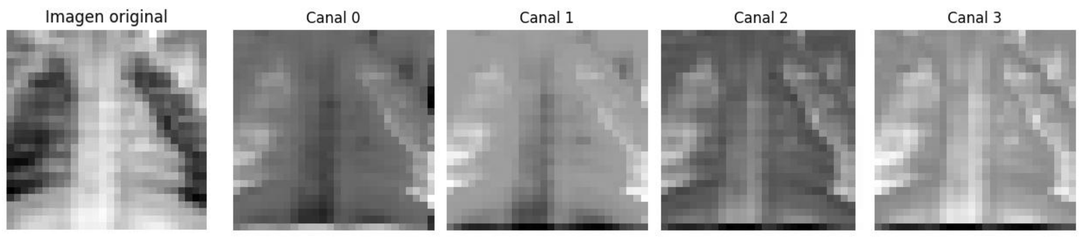

Fig. 4. Mapas de características cuánticos generados por el circuito variacional.

Tabla 1. Estructura y dimensiones del módulo convolucional clásico.

Bloque	Forma entrada	Operación principal	Forma salida
Conv1	(B,4,28,28)	Conv2d(4,16,3×3) + ReLU + MaxPool(2×2)	(B,16,14,14)
Conv2	(B,16,14,14)	Conv2d(16,32,3×3) + ReLU + MaxPool(2×2)	(B,32,7,7)
FC1	(B,32*7*7)	Linear(1568→64) + ReLU + Dropout(0.2)	(B,64)
FC2	(B,64)	Linear(64→1)	(B,1)

Resultados

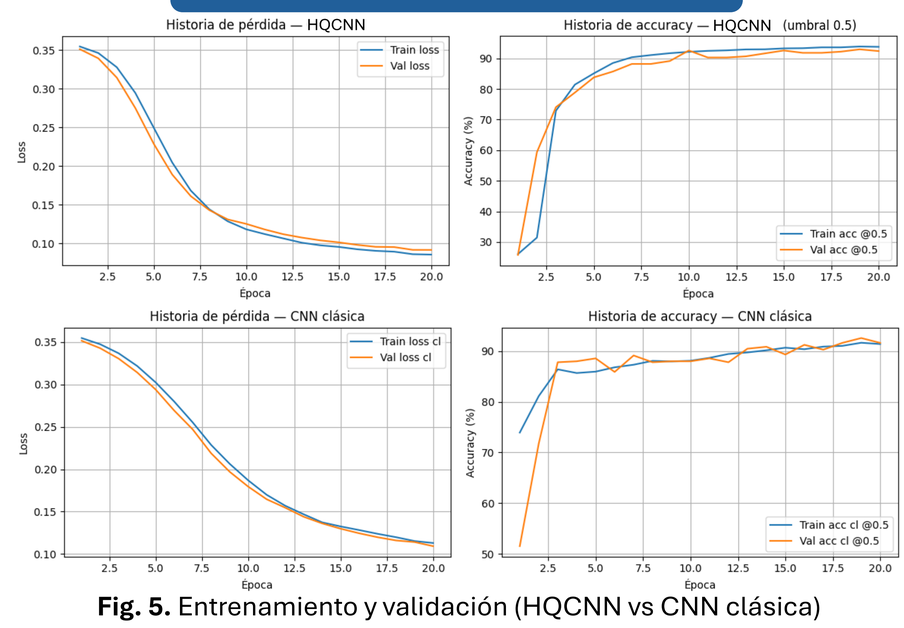

Fig. 5. Entrenamiento y validación (HQCNN vs CNN clásica)

Tabla 2. Comparación de desempeño en conjunto de prueba

MÉTRICA	HQCNN @0.5	HQCNN @THR*(0.483)	CNN @0.5	CNN @THR*(0.382)
ACCURACY (%)	88.6	89.1	87.3	86.2
RECALL	0.928	0.936	0.908	0.933
F1-SCORE	0.911	0.915	0.900	0.894
ROC-AUC	0.923	0.923	0.923	0.923

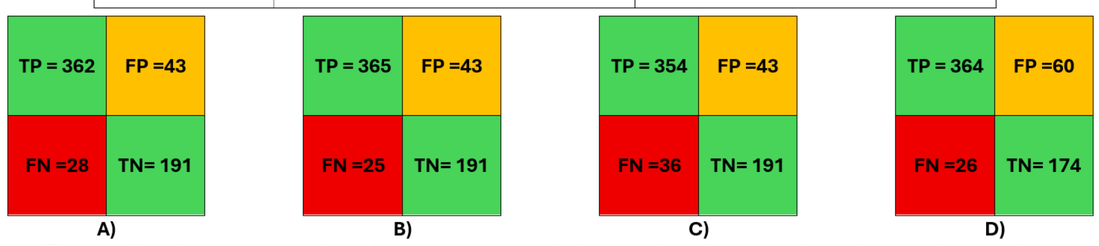

Fig. 5. Matrices de confusión para los modelos evaluados en el conjunto de prueba: A) HQCNN @ 0.5, B) HQCNN @ thr*, C) CNN clásica @ 0.5, D) CNN clásica @ thr*

Conclusiones

Se implementó una arquitectura híbrida cuántico–clásica reproducible que integra un extractor cuántico variacional en un flujo conjunto con redes neuronales convolucionales. Ambos modelos presentan capacidad discriminativa global equivalente (ROC-AUC), indicando una separación probabilística similar entre clases; sin embargo, al fijar el umbral de decisión, la QCNN muestra mejoras consistentes en recall y F1-score, reduciendo falsos negativos en el conjunto de prueba. En conjunto, estos resultados establecen una base sólida para futuras evaluaciones tanto en entornos de simulación más complejos como en dispositivos cuánticos reales.

Referencias

[1] E. H. Houssein, Z. Abohashima, M. Elhoseny, and W. M. Mohamed, "Hybrid quantum-classical convolutional neural network model for COVID-19 prediction using chest X-ray images," Journal of Computational Design and Engineering, vol. 9, no. 2, pp. 343–363, 2022.
[2] A. Senokosov, A. Sedykh, A. Sagingalieva, B. Kyriacou, and A. Melnikov, "Quantum machine learning for image classification," Machine Learning: Science and Technology, vol. 5, no. 1, 015040, 2024.
[3] M. Henderson, S. Shakya, S. Pradhan, and T. Cook, Quanvolutional Neural Networks: Powering Image Recognition with Quantum Circuits, arXiv:1904.04767 (2019).
[4] A. Matic, M. Monnet, J. M. Lorenz, B. Schachtner, and T. Messerer, Quantum-classical convolutional neural networks in radiological image classification, arXiv:2204.12390 (2022).

Contacto: sebastian_gonzalezj@ciencias.unam.mx

Disponible en GitHub: https://github.com/Bayan0708